

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

HỒ NGỌC HẢI

PHÂN LOẠI DÒNG PHIM DỰA TRÊN
POSTERS

MOVIE GENRE CLASSIFICATION
FROM POSTERS

CỦ NHÂN NGÀNH KHOA HỌC MÁY TÍNH

TP. HỒ CHÍ MINH, 2025

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH**

HỒ NGỌC HẢI - 22520380

**PHÂN LOẠI DÒNG PHIM DỰA TRÊN
POSTERS**

**MOVIE GENRE CLASSIFICATION
FROM POSTERS**

CỬ NHÂN NGÀNH KHOA HỌC MÁY TÍNH

**GIẢNG VIÊN HƯỚNG DẪN
TS. MAI TIẾN DŨNG**

TP. HỒ CHÍ MINH, 2025

Thông tin hội đồng chấm khóa luận tốt nghiệp

Hội đồng chấm khóa luận tốt nghiệp, thành lập theo Quyết định Số 25/QĐ-ĐHCNTT ngày 09 tháng 01 năm 2025 của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

- | | |
|-----------------------------|----------|
| 1. TS. Dương Việt Hằng..... | Chủ tịch |
| 2. TS. Lê Minh Hưng..... | Ủy viên |
| 3. ThS. Đỗ Văn Tiến..... | Thư ký |

Lời cảm ơn

Để hoàn thành khóa luận này, nhóm sinh viên chúng em may mắn nhận được sự hỗ trợ, động viên và hướng dẫn tận tình từ quý thầy.

TP. Hồ Chí Minh, ngày 10 tháng 01 năm 2026.

Hồ Ngọc Hải

Khoa Khoa Học Máy Tính, Lớp KHMT2022.1

MỤC LỤC

Thông tin hội đồng chấm khóa luận tốt nghiệp	i
Lời cảm ơn	ii
Mục Lục	iv
Danh sách hình vẽ	v
Danh sách bảng	vi
Tóm tắt khóa luận	1
1 TỔNG QUAN	2
1.1 Đặt vấn đề	2
1.1.1 Giới thiệu đề tài	2
1.1.2 Lý do chọn đề tài	3
2 Nghiên cứu	4
2.1 Mục tiêu nghiên cứu	4
2.2 Phạm vi nghiên cứu	5
3 Mô tả bài toán - Thách thức - Hướng giải quyết	6
3.1 Mô tả bài toán	6
3.2 Thách thức	7
3.3 Hướng giải quyết - Phương pháp	7
4 Dataset - Độ đo đánh giá - Tổng kết khóa luận	12
4.1 Mô tả dataset	12

4.2	Độ đo đánh giá và kết quả	13
4.2.1	Độ đo đánh giá	13
4.2.2	Kết quả	14
4.3	Đóng góp của khóa luận	17
4.4	Cấu trúc khóa luận	18

TÀI LIỆU THAM KHẢO	19
---------------------------	-----------

Danh sách hình vẽ

1.1	Hình ảnh minh họa cho mục tiêu bài toán	3
2.1	Hình ảnh minh họa cho EDA	5
3.1	Hình ảnh minh họa cho input và output	6
3.2	Pipeline	7
4.1	Hình ảnh minh họa dataset	13
4.2	Kết quả dự đoán	16

Danh sách bảng

4.1	So sánh các phương pháp giảm chiều: SVD, không SVD, Feature Selection và SVD with XGB.	15
-----	--	----

Tóm tắt khóa luận

Trong bối cảnh số lượng phim ngày càng gia tăng, việc phân loại thể loại phim tự động đóng vai trò quan trọng trong các hệ thống gợi ý và phân phối nội dung số. Poster phim, với vai trò là phương tiện truyền thông trực quan chính, chứa nhiều thông tin về chủ đề, bối cảnh và phong cách nghệ thuật của bộ phim, từ đó có thể được khai thác cho bài toán phân loại thể loại.

Khóa luận này nghiên cứu bài toán *phân loại thể loại phim đa nhãn (multi-label classification)* dựa trên ảnh poster. Phương pháp đề xuất kết hợp trích xuất đặc trưng toàn cục bằng mô hình DenseNet-169 được fine-tuning và đặc trưng đối tượng từ YOLOv8, nhằm xây dựng biểu diễn hình ảnh giàu thông tin hơn. Để xử lý không gian đặc trưng có số chiều lớn và hiện tượng mất cân bằng dữ liệu, khóa luận khảo sát các hướng tiếp cận gồm giảm chiều bằng Truncated SVD, chọn lọc đặc trưng dựa trên feature importance và áp dụng oversampling có trọng số.

Trên cơ sở đặc trưng đã xử lý, các mô hình LightGBM và XGBoost được sử dụng cho phân loại đa nhãn theo chiến lược *One-vs-Rest*. Ngoài ra, ngưỡng dự đoán cho từng thể loại được tối ưu riêng trên tập validation nhằm cân bằng precision và recall trong thiết lập đa nhãn.

Thực nghiệm trên bộ dữ liệu poster phim từ IMDb cho thấy phương pháp kết hợp giảm chiều bằng SVD và phân loại bằng XGBoost đạt hiệu năng tốt nhất, cải thiện rõ rệt các độ đo như F1-score, Hamming Loss và Jaccard score. Kết quả này khẳng định hiệu quả của việc kết hợp trích xuất đặc trưng sâu, xử lý đặc trưng hợp lý và mô hình phân loại mạnh trong bài toán phân loại thể loại phim đa nhãn từ poster.

Chương 1

TỔNG QUAN


Trong chương này, tác giả sẽ giới thiệu về đề tài, trình bày lý do chọn đề tài, mục tiêu nghiên cứu, đối tượng và phạm vi nghiên cứu.

1.1 Đặt vấn đề

1.1.1 Giới thiệu đề tài

Trong thời đại công nghệ điện ảnh phát triển mạnh mẽ, số lượng phim được sản xuất và phát hành hằng năm ngày càng gia tăng. Việc phân loại dòng phim và dự đoán mức độ hấp dẫn của phim đóng vai trò quan trọng đối với các nhà sản xuất, nhà phát hành cũng như các nền tảng xem phim trực tuyến. Trong đó, poster phim – một hình thức truyền thông trực quan – thường được thiết kế nhằm phản ánh chủ đề, bối cảnh và phong cách nghệ thuật của bộ phim. Hình 1.1.

1.1. Đặt vấn đề

Comedy, Drama, Fantasy  Action, Adventure, Animation <i>i</i>	Action, Drama, Mystery  Horror, Sci-Fi, Thriller <i>ii</i>	Drama, Mystery, Romance  Action, Adventure, Sci-Fi <i>iii</i>	Action, Adventure, Comedy  Drama, Horror, Romance <i>iv</i>	Action, Adventure, Fantasy  Drama, Horror, Mystery <i>v</i>	Drama, Romance, —  Action, Horror, — <i>vi</i>	Biography, Drama, —  Action, Adventure, Sci-Fi <i>vii</i>	Adventure, Comedy, Fantasy  Drama, Horror, Mystery <i>viii</i>
Comedy, Fantasy —  Drama, Mystery, — <i>ix</i>	Mystery, Thriller —  Comedy, Drama, Romance <i>x</i>	Biography, Drama —  Action, Adventure, Thriller <i>xi</i>	Action, Drama, Sci-Fi  Biography, Drama, Mystery <i>xii</i>	Comedy, Drama, Fantasy  Biography, Drama, Romance <i>xiii</i>	Drama, Romance, Sci-Fi  Biography, Crime, Drama <i>xiv</i>	Drama, Fantasy, Mystery  Biography, Drama, Romance <i>xv</i>	Drama, Fantasy, Mystery  Biography, Drama, Mystery <i>xvi</i>

Hình 1.1: Hình ảnh minh họa cho mục tiêu bài toán

1.1.2 Lý do chọn đề tài

Việc phân loại thể loại phim và dự đoán chất lượng phim là nhu cầu thiết yếu trong các hệ thống gợi ý và các nền tảng phân phối nội dung số. Đồng thời poster phim là nguồn dữ liệu trực quan phổ biến và có nhiều thông tin tiềm ẩn để mở thêm hướng có thể có như đánh giá score phim hay gom nhóm thể loại. Lý do phần lớn từ nguồn tham khảo của bài báo : https://cs230.stanford.edu/projects_winter_2020/reports/32643471.pdf
<https://arxiv.org/pdf/2309.12022v2>

Chương 2

Nghiên cứu

2.1 Mục tiêu nghiên cứu

Trong nghiên cứu này, chúng tôi tập trung vào việc xây dựng mô hình phân loại đa nhãn (multi-label classification) các thể loại phim dựa trên ảnh poster và file csv. Đặc biệt, mô hình cần có khả năng phân biệt và nhận diện chính xác nhiều thể loại cùng xuất hiện trong một poster, đồng thời khắc phục vấn đề mất cân bằng dữ liệu giữa các dòng phim. Cụ thể, đề tài tập trung vào các mục tiêu sau:

1. Tìm hiểu tổng quan về bài toán phân loại thể loại phim từ poster, hệ thống hóa cơ sở lý thuyết về thị giác máy tính, học sâu và các phương pháp multi-label classification nhằm nắm bắt bức tranh toàn cảnh của lĩnh vực nghiên cứu.
2. Khảo sát và phân tích các phương pháp hiện có trong việc phân loại dòng phim từ dữ liệu trực quan, so sánh ưu và nhược điểm của từng hướng tiếp cận, từ đó xác định những thách thức như sự đa dạng hình ảnh trong poster và hiện tượng mất cân bằng dữ liệu giữa các thể loại.
3. Xây dựng và tiền xử lý tập dữ liệu poster phim với nhãn multi-label từ IMDb, đảm bảo tính cân đối và khả năng huấn luyện cho mô hình, đồng thời đề xuất cách chia dữ liệu phù hợp cho train/validation/test.
4. Dựa vào paper, nghiên cứu và đề xuất mô hình kết hợp giữa Residual Dense Transformer và mô-đun xác suất (probabilistic module) nhằm trích xuất đặc

2.2. Phạm vi nghiên cứu


trưng thị giác hiệu quả, cải thiện khả năng nhận diện nhiều thể loại đồng thời, và giảm thiểu nhãn dư thừa.

5. Triển khai huấn luyện, đánh giá và so sánh hiệu quả mô hình trên tập dữ liệu chuẩn, sử dụng các chỉ số như Precision, Recall, F1-score.

Thông qua nghiên cứu này, đề tài không chỉ đóng góp giải pháp kỹ thuật cho bài toán phân loại dòng phim từ poster mà còn mở ra tiềm năng ứng dụng trong hệ thống gợi ý phim, phân tích dữ liệu truyền thông, và khai thác hiệu quả thông tin thị giác trong các ứng dụng thực tiễn.

2.2 Phạm vi nghiên cứu

Phạm vi dataset gồm có 28 thể loại của những bộ phim được ra mắt tầm khoảng 1980 đến 2018, nhưng vì có một vài trường hợp có những nhãn hiếm cho nên nhóm gộp những nhãn đó thành một nhãn mới có tên "Other". Lý do là dataset bị mất cân bằng giữa các nhãn, sinh ra bị bias.



Hình 2.1: Hình ảnh minh họa cho EDA

Trong bộ dataset gồm có những ảnh poster bị lỗi cũng như phần "Genre" trong csv bị NaN nên chỉ lọc lại còn 39 140 ảnh (ban đầu là 39 515).


Chương 3

Mô tả bài toán - Thách thức - Hướng giải quyết

3.1 Mô tả bài toán


Bài toán là phân loại thể loại phim đa nhãn từ poster ảnh (Multi-label Genre Classification from Poster), cùng với :

- Input: Dữ liệu đầu vào là ảnh poster bất kì của phim. Poster được thu thập từ IMDb, với số lượng thể loại tối đa 3 nhãn cho mỗi poster.
- Output: Một hoặc nhiều thể loại (genre) gán cho phim đó (multi-label). Vì phim thường có thể thuộc nhiều thể loại (ví dụ: “hành động + giả tưởng”, “kịch tính + tội phạm”, v.v.).



Hình 3.1: Hình ảnh minh họa cho input và output

Pipeline cho bài toán này như sau:



Hình 3.2: Pipeline

3.2 Thách thức

Bài toán gồm những thách thức sau:

1. **Đa nhãn:** Cần dự đoán số lượng thể loại không cố định và phải chọn đúng thể loại mà poster gợi ý, đồng thời loại bỏ các thể loại không phù hợp.
2. **Mất cân bằng dữ liệu:** Một số thể loại xuất hiện rất nhiều trong tập dữ liệu, trong khi các thể loại hiếm xuất hiện ít hơn, làm cho mô hình dễ thiên về các lớp phổ biến.
3. **Biểu diễn hình ảnh phong phú và đa dạng:** poster phim có nhiều phong cách, màu sắc, bố cục khác nhau, đôi khi chỉ gợi ý rất tinh tế về thể loại nên mô hình phải hiểu được các yếu tố thị giác khác.

3.3 Hướng giải quyết - Phương pháp

Dựa trên các hướng tiếp cận đã được đề xuất trong các paper liên quan đến bài toán phân loại đa nhãn cho poster phim, đồng thời dựa vào pipeline mà chúng tôi đã triển khai trong thực nghiệm, quy trình giải quyết bài toán được đề xuất gồm các bước sau:

1. **Tiền xử lý dữ liệu:** Loại bỏ các poster bị lỗi, không đọc được, hoặc chứa thông tin không đầy đủ (ví dụ: nhãn thể loại bị thiếu hoặc bị ghi *Null*). Các mẫu hợp lệ được chuẩn hoá kích thước và ánh sáng để đảm bảo tính đồng nhất trước khi đưa vào mô hình trích xuất đặc trưng.

3.3. Hướng giải quyết - Phương pháp

2. **Giải quyết mất cân bằng dữ liệu:** Phân bố thể loại trong dataset không đồng đều, dẫn đến hiện tượng bias khi huấn luyện. Để giảm độ mất cân bằng, chỉ giữ lại các nhãn có tần suất xuất hiện lớn hơn 4500 mẫu (*Comedy, Action, Romance, Drama, Crime, Thriller*), các nhãn còn lại được gom vào một lớp chung **Other**. Chiến lược này giúp mô hình học ổn định hơn và giảm nhiễu từ các nhãn hiếm.
3. **Multi-label và chia dữ liệu:** Để xử lý bài toán phân loại đa nhãn, danh sách các thể loại phim được chuyển đổi sang dạng vector nhị phân bằng `MultiLabelBinarizer`, trong đó mỗi cột biểu diễn một thể loại và giá trị 1 cho biết phim thuộc thể loại đó. Dữ liệu sau đó được chia thành ba phần: 80% để huấn luyện, 10% để kiểm tra trong quá trình huấn luyện (validation), và 10% để đánh giá cuối cùng (test). Các ảnh poster được tiền xử lý bằng cách đổi kích thước về 224×224, chuyển sang tensor và chuẩn hoá theo thống kê của ImageNet để phù hợp với mô hình DenseNet đã được huấn luyện trước. Cuối cùng, một lớp `Dataset` và `DataLoader` được sử dụng để tải ảnh và nhãn theo từng batch, với `shuffle=True` cho tập huấn luyện nhằm tăng tính đa dạng và giúp mô hình học ổn định hơn.



4. **Trích xuất đặc trưng hình ảnh (Visual Features):** Sử dụng mô hình DenseNet-169 pretrained trên ImageNet để trích xuất đặc trưng trực quan từ poster, sau đó fine-tuning. DenseNet được chọn vì khả năng truyền thông tin tốt giữa các tầng, giúp thu giữ chi tiết hình ảnh quan trọng như bố cục, màu sắc, khuôn mặt, hành động và bối cảnh. Trong quá trình fine-tuning, các siêu tham số được lựa chọn cẩn thận nhằm đảm bảo mô hình học ổn định và tránh overfitting. Cụ

thể, tốc độ học (*learning rate*) được đặt rất nhỏ trong khoảng từ 1×10^{-4} đến 1×10^{-5} để tránh làm biến đổi quá mạnh các trọng số pretrained. Optimizer được sử dụng là Adam vì khả năng hội tụ nhanh và ổn định trên các bài toán thị giác. Batch size được chọn ở mức vừa phải (từ 16 đến 32 mẫu) để cân bằng giữa hiệu quả huấn luyện và giới hạn bộ nhớ GPU. Ngoài ra, dữ liệu đầu vào được tăng cường bằng các phép biến đổi cơ bản như random crop, horizontal flip và thay đổi độ sáng nhẹ nhằm giúp mô hình học được các biến thiên tự nhiên của poster, từ đó tăng khả năng tổng quát hoá. Việc áp dụng dropout ở tầng cuối của DenseNet cũng góp phần giảm hiện tượng overfitting trong quá trình fine-tuning.

5. **Kết hợp thông tin đối tượng từ YOLOv8:** YOLOv8 pretrained (80 lớp COCO) được sử dụng để phát hiện các đối tượng xuất hiện trên poster (nhân vật, vũ khí, phương tiện, bối cảnh, đồ vật,...). Các đặc trưng này được mã hoá lại thành vector tần suất đối tượng, sau đó kết hợp với embedding từ DenseNet. Nhờ vậy mô hình có thêm thông tin ngữ nghĩa giúp nhận diện các thể loại phụ thuộc vào đối tượng (ví dụ: "gun" thường đi kèm *Action / Crime*, "kiss" liên quan *Romance*, "dark room" liên quan *Horror / Thriller*).
6. **Hướng tiếp cận:** Trong bài toán này, sau khi ghép đặc trưng từ DenseNet169 và YOLOv8, vector thu được có số chiều rất lớn và chứa nhiều nhiễu. Do đó, ba hướng tiếp cận chính được sử dụng để xử lý và tối ưu đặc trưng đầu vào:

- a) **Giảm chiều bằng SVD (Truncated SVD)**

Phương pháp SVD được sử dụng nhằm nén không gian đặc trưng có kích thước lớn vào không gian thấp hơn nhưng vẫn giữ lại phần lớn thông tin quan trọng, ở đây nén thủ công còn 550 chiều. Việc giảm chiều bằng SVD giúp:

- Giảm nhiễu và hạn chế hiện tượng overfitting,
- Tăng tốc độ học của LightGBM,
- Tạo đặc trưng ổn định hơn cho bài toán phân loại đa nhãn.

- b) **Không sử dụng SVD (giữ nguyên toàn bộ đặc trưng)**

Trong hướng tiếp cận này, toàn bộ đặc trưng từ DenseNet169 và YOLOv8

được giữ nguyên mà không thực hiện giảm chiều. Cách này cho phép mô hình khai thác đầy đủ thông tin ban đầu nhưng có thể dẫn đến:

- Mô hình phức tạp hơn,
- Thời gian huấn luyện lâu hơn,
- Nguy cơ overfitting cao do số chiều lớn.

c) **Feature Selection (Lọc đặc trưng bằng LightGBM)**

Thay vì giảm chiều bằng SVD, hướng tiếp cận này sử dụng LightGBM-Classifer để chọn ra các đặc trưng quan trọng nhất. Cơ chế chọn lọc dựa trên feature importance gain mà LightGBM học được từ dữ liệu. Các đặc trưng có độ quan trọng thấp hơn ngưỡng trung vị (median importance) sẽ bị loại bỏ, chỉ giữ lại những đặc trưng đóng góp nhiều nhất cho việc phân biệt thể loại phim. Hướng tiếp cận này giúp:

- Loại bỏ đặc trưng dư thừa gây nhiễu,
- Tăng khả năng tổng quát hóa,
- Giúp mô hình gọn nhẹ và hiệu quả hơn mà vẫn giữ lại thông tin quan trọng.

7. **Oversampling:** Tiến hành oversampling ở không gian embedding nhằm tăng tỉ lệ xuất hiện của nhãn hiếm hơn sau khi gom nhóm. Điều này giúp LightGBM không bị thiên lệch quá nhiều về các nhãn lớn.
8. **LightGBM cho phân loại đa nhãn:** Từ đặc trưng đầu vào đã giảm chiều(hoặc không), mô hình LightGBM được sử dụng như bộ phân loại. Nhờ khả năng xử lý tốt dữ liệu nhiều chiều, tốc độ huấn luyện nhanh và khả năng mô hình hóa quan hệ phi tuyến, LightGBM phù hợp để học xác suất xuất hiện của từng thể loại trong thiết lập multi-label. Mỗi nhãn được huấn luyện như một mô hình binary riêng biệt (One-vs-Rest).
9. **XGBoost cho phân loại đa nhãn:** Từ đặc trưng đầu vào sau khi giảm chiều bằng Truncated SVD, mô hình XGBoost được áp dụng như bộ phân loại chính. Nhờ cơ chế boosting dựa trên đạo hàm bậc hai, khả năng regularization mạnh và cấu trúc cây phát triển theo chiều sâu, XGBoost học được các quan hệ phi tuyến phức tạp từ embedding hình ảnh. Trong thiết lập phân loại đa nhãn, mỗi

3.3. Hướng giải quyết - Phương pháp

nhân được huấn luyện dưới dạng một mô hình nhị phân độc lập theo chiến lược *One-vs-Rest*, cho phép ước lượng xác suất xuất hiện của từng thể loại phim một cách ổn định và được hiệu chỉnh tốt hơn so với LightGBM.


10. **Tối ưu threshold cho từng nhãn:** Vì LightGBM cho ra xác suất, cần đặt ngưỡng quyết định (*threshold*) cho mỗi nhãn vì sự mất cân bằng giữa các nhãn. Thay vì dùng một threshold mặc định (0.5), threshold được tối ưu riêng cho từng lớp dựa trên tập validation để:

- giảm dự đoán dư thừa (quá nhiều thể loại),
- cân bằng precision/recall cho từng nhãn,
- cải thiện F1-score macro và micro.

Các threshold tối ưu tìm được cho từng mô hình như sau:

- **LightGBM:** Action (0.198), Comedy (0.320), Crime (0.191), Drama (0.424), Other (0.476), Romance (0.197), Thriller (0.184).
- **XGBoost:** Action (0.083), Comedy (0.179), Crime (0.049), Drama (0.226), Other (0.272), Romance (0.082), Thriller (0.040).

Điểm đáng chú ý là XGBoost có xu hướng sinh xác suất “mềm” và thận trọng hơn LightGBM, dẫn đến các ngưỡng tối ưu thấp hơn — đặc biệt với các nhãn hiếm (Crime, Thriller, Romance). Điều này giúp tăng recall và cải thiện đáng kể F1-score trong thiết lập phân loại đa nhãn.



Chương 4

Dataset - Độ đo đánh giá - Tổng kết khóa luận


4.1 Mô tả dataset

Cùng với dataset từ nguồn <https://www.kaggle.com/datasets/neha1703/movie-genre-from-its-poster/data> (đã được tác giả cập nhật full poster):

- Dataset gồm: Ảnh poster phim có chứa filename là số ID trên web đánh giá phim IMDB (tổng cộng 39 515 ảnh), và file csv gồm các cột:
 - "imdbid": Số thứ tự id của phim trên trang web IMDB.
 - "Imdb Link": Đường link dẫn tới phim trên trang web IMDB.
 - "Title": Tựa đề phim của poster.
 - "IMDB Score": Điểm số đánh giá chất lượng phim trên trang web IMDB.
 - "Genre": Thể loại của phim đó (có thể có 1 nhãn, có thể có đa nhãn).
 - "Poster": Đường link ảnh poster trên trang web IMDB.

4.2. Độ đo đánh giá và kết quả

imdbId	Imdb Link	Title	IMDB Score	Genre	Poster
114709	http://www.imdb.com/title/tt0114709	Toy Story (1995)	8.3	Animation Adventure Comedy	https://images-na.ssl-images-amazon.com/images/M/MV5BMTY1NDU0NjUwOV5BMl5BanBnXkFtZTcwMzY0MTUwOQ@@._V1_SX300.jpg
113497	http://www.imdb.com/title/tt0113497	Jumanji (1995)	6.9	Action Adventure Fantasy	https://images-na.ssl-images-amazon.com/images/M/MV5BMTY1NDU0NjUwOV5BMl5BanBnXkFtZTcwMzY0MTUwOQ@@._V1_SX300.jpg
113228	http://www.imdb.com/title/tt0113228	Grumpier (1995)	6.6	Comedy Romance	https://images-na.ssl-images-amazon.com/images/M/MV5BMTY1NDU0NjUwOV5BMl5BanBnXkFtZTcwMzY0MTUwOQ@@._V1_SX300.jpg



Hình 4.1: Hình ảnh minh họa dataset

4.2 Độ đo đánh giá và kết quả

4.2.1 Độ đo đánh giá

Trong thực nghiệm, mô hình được đánh giá bằng nhiều độ đo khác nhau để đo lường mức độ hiệu quả. Các độ đo chính bao gồm **Precision**, **Recall**, **F1-score** (micro và macro):

$$\text{Precision}_{\text{micro}} = \frac{\sum_{l=1}^L TP_l}{\sum_{l=1}^L (TP_l + FP_l)} \quad \text{Precision}_{\text{macro}} = \frac{1}{L} \sum_{l=1}^L \frac{TP_l}{TP_l + FP_l} \quad (4.1)$$

$$\text{Recall}_{\text{micro}} = \frac{\sum_{l=1}^L TP_l}{\sum_{l=1}^L (TP_l + FN_l)} \quad \text{Recall}_{\text{macro}} = \frac{1}{L} \sum_{l=1}^L \frac{TP_l}{TP_l + FN_l} \quad (4.2)$$

$$\text{F1}_{\text{micro}} = \frac{2 \cdot \text{Precision}_{\text{micro}} \cdot \text{Recall}_{\text{micro}}}{\text{Precision}_{\text{micro}} + \text{Recall}_{\text{micro}}} \quad \text{F1}_{\text{macro}} = \frac{1}{L} \sum_{l=1}^L \text{F1}_l \quad (4.3)$$

Bên cạnh đó, dựa theo công thức trong bài báo tham khảo, ta còn tính **Hamming Loss** để đo tỷ lệ nhãn dự đoán sai:

$$\text{Hamming Loss} = \frac{1}{NL} \sum_{i=1}^N \sum_{j=1}^L \mathbb{1}[y_{ij} \neq \hat{y}_{ij}] \quad (4.4)$$

Từ đó suy ra accuracy per-class:

$$\text{Average Accuracy} = 1 - \text{Hamming Loss} \quad (4.5)$$

Ngoài ra, báo cáo còn sử dụng **At-least-one Accuracy** để đo trường hợp mô hình dự đoán *ít nhất một nhãn đúng* cho mỗi mẫu:

$$\text{At-least-one Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(|Y_i \cap \hat{Y}_i| > 0) \quad (4.6)$$

Ngoài ra, báo cáo cũng sử dụng thêm độ đo **Jaccard per-sample** (còn gọi là *Intersection over Union* – IoU cho từng mẫu) nhằm đánh giá mức độ trùng khớp giữa tập nhãn dự đoán và tập nhãn thật. Độ đo này được định nghĩa như sau:

$$\text{Jaccard}(i) = \frac{|Y_i \cap \hat{Y}_i|}{|Y_i \cup \hat{Y}_i|} \quad (4.7)$$

Giá trị Jaccard bằng 1 khi mô hình dự đoán đúng toàn bộ nhãn của mẫu, và bằng 0 khi hai tập nhãn hoàn toàn không trùng nhau. Đây là độ đo quan trọng để đánh giá mức độ khớp tổng quát giữa nhãn thật và nhãn dự đoán trong bài toán phân loại đa nhãn.

4.2.2 Kết quả

Bảng dưới đây tổng hợp kết quả của ba phương pháp: (1) **Sử dụng SVD**, (2) **Không dùng SVD**, (3) **Feature Selection bằng LightGBM** và (4) **SVD với XGB**.

4.2. Độ đo đánh giá và kết quả

Độ đo	SVD	Không SVD	Feature Selection	SVD with XGB
Precision (micro)	0.60	0.60	0.59	0.62
Recall (micro)	0.61	0.61	0.61	0.62
F1-score (micro)	0.60	0.60	0.60	0.62
Precision (macro)	0.53	0.51	0.50	0.55
Recall (macro)	0.40	0.41	0.40	0.45
F1-score (macro)	0.40	0.40	0.40	0.47
Hamming Loss	0.22	0.22	0.22	0.21
Accuracy per-label	0.78	0.78	0.78	0.79
At-least-one Acc.	0.91	0.90	0.90	0.91
Jaccard (samples)	0.48	0.48	0.48	0.50

Bảng 4.1: So sánh các phương pháp giảm chiều: SVD, không SVD, Feature Selection và SVD with XGB.

Nhận xét: Kết quả cho thấy ba phương pháp đầu tiên (*SVD, không dùng SVD và Feature Selection bằng LightGBM*) có hiệu năng khá tương đồng trên hầu hết các độ đo. Điều này phản ánh rằng bộ đặc trưng gốc (DenseNet169 + YOLOv8) đã chứa lượng thông tin giàu và ổn định, nên việc giảm chiều hoặc chọn lọc đặc trưng chỉ mang lại khác biệt nhỏ.

Tuy nhiên, phương pháp SVD bằng XGBoost cho thấy mức cải thiện rõ rệt trên toàn bộ các độ đo quan trọng. Cụ thể, F1-score (micro) tăng lên 0.62, F1-score (macro) đạt 0.47 — cao hơn đáng kể so với ba phương pháp còn lại (0.40). Hamming Loss giảm xuống mức thấp nhất (0.21), Jaccard tăng lên 0.50 và Accuracy per-label đạt 0.79.

Những kết quả này cho thấy việc giảm chiều bằng SVD giúp loại bỏ nhiễu và làm mượt embedding, trong khi XGBoost khai thác tốt hơn cấu trúc phi tuyến còn lại của không gian đặc trưng, đặc biệt trong bối cảnh phân loại đa nhãn và mất cân bằng lớp.

4.2. Độ đo đánh giá và kết quả



True: Comedy, Other, Thriller
Pred: Other, Thriller



Hình 4.2: Kết quả dự đoán

Ưu điểm và hạn chế:

Kết quả ảnh minh họa cho thấy những poster có thể loại phim Drama và Comedy khá tốt cùng với Action và Romance. Ở đây là những posters có màu sắc tươi sáng và bố cục người hay vật thể.

Tuy nhiên, đối với những trường hợp poster phim có yếu tố kinh dị giật gân thì đôi lúc không thể hiện đủ bản chất của nó. Ví dụ như có những poster thể hiện những cảnh kinh dị nhưng bản chất nó có yếu tố Comedy ở trong đây, mô hình chỉ cho ra phần kinh dị thôi chứ không có Comedy.

4.3 Đóng góp của khóa luận

Khi hoàn thành, khóa luận mang lại những đóng góp chính như sau:

- **Xây dựng pipeline đầy đủ cho bài toán phân loại đa nhãn từ poster phim:** Đề tài đã xây dựng hoàn chỉnh quy trình xử lý dữ liệu, trích xuất đặc trưng và huấn luyện mô hình từ dữ liệu poster và thông tin thể loại trong file CSV, đảm bảo có thể tái sử dụng cho các bài toán tương tự.
- **Đề xuất phương pháp kết hợp đặc trưng thị giác và đối tượng:** Khóa luận áp dụng mô hình DenseNet-169 để trích xuất đặc trưng toàn cục của hình ảnh và sử dụng YOLOv8 để trích xuất đặc trưng đối tượng (object-level), từ đó kết hợp hai nguồn thông tin nhằm tăng độ chính xác nhận diện thể loại phim.
- **Giải quyết vấn đề mất cân bằng dữ liệu trong phân loại đa nhãn:** Thực hiện gộp các nhãn hiếm thành một nhãn chung “Other”, đồng thời áp dụng phương pháp oversampling có trọng số (sample-weighted oversampling) để giảm thiên lệch của mô hình trong huấn luyện.
- **Cải thiện biểu diễn đặc trưng thông qua giảm chiều SVD và hướng tiếp cận khác:** Áp dụng kỹ thuật Truncated SVD để nén đặc trưng từ DenseNet và YOLO, giúp giảm nhiễu và tăng khả năng tổng quát hóa cho mô hình khi phân loại đa nhãn.
- **Đánh giá hiệu quả mô hình đa nhãn trên nhiều độ đo:** Ngoài các chỉ số cơ bản như Precision, Recall, F1-score, khóa luận còn bổ sung thêm Hamming Loss, Accuracy và Jaccard score để đánh giá toàn diện mô hình.

- **Đóng góp thực nghiệm và trực quan hóa:** Xây dựng phần thực nghiệm minh họa kết quả dự đoán trực quan trên các poster phim cụ thể, phân tích các lỗi thường gặp và biểu đồ phân bố thể loại trước/sau khi gộp “Other”, hỗ trợ đánh giá tính hiệu quả của phương pháp.

4.4 Cấu trúc khóa luận

Khóa luận được bố cục thành 5 chương như sau:

Chương 1: Tổng quan - Giới thiệu về lý do chọn đề tài, bối cảnh và tầm quan trọng của việc phân loại thể loại phim từ poster. Trình bày mục tiêu, phạm vi và định hướng nghiên cứu của khóa luận.

Chương 2: Cơ sở lý thuyết và các nghiên cứu liên quan - Trình bày cơ sở lý thuyết về học sâu (Deep Learning), thị giác máy tính (Computer Vision), bài toán phân loại đa nhãn (Multi-label Classification), cũng như các công trình và mô hình liên quan như DenseNet, YOLO, Transformer, SVD,...

Chương 3: Mô tả bài toán và phương pháp đề xuất - Phân tích bài toán phân loại thể loại phim đa nhãn, chỉ ra các thách thức và trình bày pipeline tổng thể của hệ thống. Giới thiệu chi tiết về quy trình tiền xử lý dữ liệu, trích xuất đặc trưng bằng DenseNet và YOLO, kỹ thuật giảm chiều, và mô hình phân loại LGBM kết hợp đa đặc trưng.

Chương 4: Thực nghiệm và đánh giá - Trình bày chi tiết dataset sử dụng, cách chia dữ liệu train/validation/test, các độ đo đánh giá (Precision, Recall, F1-score, Hamming Loss, Accuracy,...). Phân tích và so sánh kết quả, minh họa trực quan đầu ra của mô hình qua các poster mẫu.

Chương 5: Kết luận và hướng phát triển - Tổng kết kết quả đạt được, nêu ra các hạn chế của mô hình hiện tại và đề xuất các hướng nghiên cứu tiếp theo như tích hợp mô hình Transformer, tăng cường dữ liệu, hoặc sử dụng thông tin văn bản (text metadata) kết hợp hình ảnh để cải thiện hiệu năng.

TÀI LIỆU THAM KHẢO

1. Samuel Sung and Rahul Chokshi, *Movie Genre Classification Using Posters with Deep Convolutional Neural Networks*, CS230: Deep Learning Final Project Report, Stanford University, 2020. Available at: https://cs230.stanford.edu/projects_winter_2020/reports/32643471.pdf.
2. Utsav Kumar Nareti, Chandranath Adak, and Soumi Chattopadhyay, *Multi-Label Image Classification via Feature Enhancement and Adaptive Label Correlation*, Available at: <https://arxiv.org/abs/2309.12022>.
3. Nayeem Hossain, Md. Martuza Ahamad, Sakifa Aktar, and Mohammad Ali Moni, *A Unified Focal Loss Framework for Class-Imbalanced Multi-Label Classification*, IEEE Transactions on Neural Networks and Learning Systems, 2021. Available at: <https://ieeexplore.ieee.org/document/9396778>.
4. Wei-Ta Chu and Hung-Jui Guo, *Multi-Label Scene Classification with Label Relation Modeling*, Proceedings of the ACM International Conference on Multimedia, ACM, 2017. Available at: <https://dl.acm.org/doi/10.1145/3132515.3132516>.
5. Grigorios Tsoumakas and Ioannis Katakis, *Multi-Label Classification: An Overview*, IEEE Transactions on Knowledge and Data Engineering. Available at: https://www.researchgate.net/publication/273859036_Multi-Label_Classification_An_Overview.